Mata Kuliah: Predictive Analytics (Midterm Examination)

Jenis Tugas: Proyek Individu Klasifikasi Biner (*Binary Classification*)

Tanggal Akses & Penyusunan: 28 September 2026

1. Latar Belakang Masalah

Kencan kilat (*speed dating*) memberikan durasi interaksi tatap muka yang sangat singkat (sekitar 4 menit) bagi dua individu untuk saling menilai dan memutuskan apakah mereka ingin melanjutkan komunikasi ke kencan kedua. Fenomena ini menimbulkan pertanyaan analitis: faktor apa yang sebenarnya memicu kecocokan timbal balik (*romantic chemistry*) dalam waktu yang sangat terbatas tersebut?

Bagi industri aplikasi kencan daring (*dating apps*) maupun platform perjodohan modern, memahami pola ini menjadi fondasi utama dalam merancang sistem rekomendasi. Jika platform dapat memprediksi probabilitas kecocokan dua pihak secara lebih akurat, pengguna akan disajikan profil yang lebih relevan. Dampak bisnisnya adalah berkurangnya kelelahan mencari pasangan (*dating app fatigue*), peningkatan angka keberhasilan pertemuan, dan peningkatan retensi pengguna aktif pada platform.

2. Gambaran Dataset dan Variabel Target

- **Sumber Data:** Dataset publik *Speed Dating Experiment* yang dikumpulkan oleh peneliti Columbia Business School (Ray Fisman dan Sheena Iyengar) melalui repositori Kaggle.
- **Unit Analisis:** Satu sesi percakapan tatap muka berdurasi 4 menit antara partisipan dan pasangannya.
- **Target Prediksi:** Variabel biner match:
    - Nilai 1 menunjukkan kedua belah pihak sama-sama setuju untuk bertemu kembali (*mutual match*).
    - Nilai 0 menunjukkan salah satu atau kedua belah pihak menolak pertukaran kontak.
- **Karakteristik & Kualitas Data:**
    - Berisi 8.378 baris observasi interaksi.
    - Memiliki ketidakseimbangan kelas (*class imbalance*) yang signifikan: 83,53% interaksi berakhir tanpa kecocokan (0), dan hanya 16,47% yang berhasil menghasilkan kecocokan (1).
    - Nilai yang hilang (*missing values*) pada fitur penilaian numerik diisi menggunakan strategi nilai tengah (*median imputation*) agar tidak terdistorsi oleh nilai ekstrem (*outlier*).
- **Pencegahan Kebocoran Data (*Target Leakage Prevention*):** Variabel keputusan langsung individu (dec dan dec_o) dieliminasi sepenuhnya dari proses pelatihan model prediktif. Variabel tersebut merepresentasikan hasil akhir keputusan saat itu juga, sehingga jika disertakan akan menghasilkan ilusi akurasi sempurna (*data leakage*) yang tidak realistis untuk penerapan di lapangan.

3. Metodologi dan Model yang Dikembangkan

Data dibagi menjadi 80% data latih (*training set*) sebanyak 6.702 sampel dan 20% data uji (*test set*) sebanyak 1.676 sampel menggunakan stratifikasi target untuk mempertahankan rasio kelas. Penskalaan fitur (*StandardScaler*) diestimasi secara ketat hanya pada data latih guna menjamin kebersihan evaluasi (*no data contamination*).

Sesuai ketentuan tugas, tiga pendekatan model dibangun dan diuji:

1. **Baseline Model (Majority Class):** Menggunakan *Dummy Classifier* yang selalu memprediksi kelas dominan (0) sebagai tolok ukur kinerja minimal.
2. **Logistic Regression (Class-Weighted):** Model parametrik linier yang dilengkapi penyeimbang bobot kelas untuk memberi perhatian lebih besar pada kelas minoritas (*match*).
3. **Random Forest Classifier:** Model berbasis gabungan pohon keputusan (*ensemble*) dengan 100 estimator dan benih acak terkontrol (*random_state=42*) guna menjamin keterulangan (*reproducibility*).

4. Hasil Evaluasi Model

Pengujian performa pada data uji menghasilkan ringkasan metrik sebagai berikut:

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Baseline (Majority Class)	83.53%	0.00%	0.00%	0.0000	0.5000
Logistic Regression	75.12%	37.65%	**77.90%**	**0.5077**	0.8244
Random Forest	**85.08%**	**63.00%**	22.83%	0.3351	**0.8460**

Temuan Evaluasi:

- **Kelemahan Baseline:** Baseline mencatatkan akurasi 83,53% semata-mata karena menebak semua sampel bernilai nol, namun nilai Recall dan F1-Score sebesar 0 membuktikan bahwa model ini gagal mendeteksi satu pun kecocokan riil. Ini menegaskan perlunya metrik sensitif kelas seperti F1-Score dan ROC-AUC.
- **Keunggulan Logistic Regression:** Model ini berhasil menjaring 215 dari 276 kecocokan riil (Recall mencapai 77,90%), menjadikannya sangat peka terhadap peluang kecocokan.

- **Karakter Random Forest:** Model pohon menghasilkan nilai ROC-AUC tertinggi (0.8460) dan presisi rekomendasi yang lebih bersih (63,00%), namun memiliki kecenderungan konservatif dalam memprediksi kelas positif.

5. Pemilihan Model Akhir dan Kontribusi Fitur (*Feature Importance*)

Model yang direkomendasikan untuk implementasi dasar adalah **Logistic Regression dengan pembobotan kelas (*class-weight balanced*)**. Dalam skenario platform perjodohan, biaya kehilangan potensi pasangan cocok (*False Negative*) dinilai jauh lebih merugikan bagi kepuasan pengguna daripada merekomendasikan profil yang belum tentu cocok (*False Positive*).

Berdasarkan analisis kontribusi fitur pada model pohon keputusan (*Random Forest Feature Importance*):

1. **Persepsi Humor Timbal Balik (fun_mean):** Kesan menyenangkan dan selera humor yang setara menjadi atribut paling kuat yang memicu kecocokan timbal balik.
2. **Daya Tarik Fisik Timbal Balik (attr_mean):** Daya tarik visual kedua pihak tetap menjadi faktor penentu cepat pada menit-menit awal perkenalan.
3. **Korelasi Minat Bersama (int_corr):** Keselarasan hobi dan preferensi gaya hidup memberikan kontribusi stabil terhadap pembentukan kecocokan.
4. **Faktor Demografi Rendah Korelasi:** Kesamaan ras (samerace) dan selisih usia (age_diff) memiliki kontribusi prediktif yang jauh lebih rendah dibandingkan penilaian subjektif interaksi langsung.

6. Rekomendasi Praktis

- **Optimalisasi Algoritma Aplikasi:** Kurangi ketergantungan sistem kurasi pada filter demografi statis (seperti kesamaan latar belakang etnis atau usia kaku). Alihkan prioritas algoritma pencocokan pada analisis kesamaan minat/hobi interaktif (int_corr).
- **Panduan Profil Pengguna:** Dorong pengguna platform untuk menampilkan sisi kepribadian yang ramah, santai, dan komunikatif di profil mereka, karena persepsi rasa humor dan keseruan interaksi terbukti memiliki bobot penentu terbesar dalam menciptakan kecocokan instan.

7. Batasan Analisis (*Limitations*) & Langkah Lanjutan

- **Keterbatasan Sampel:** Dataset diperoleh dari eksperimen mahasiswa pascasarjana di satu universitas Amerika Serikat pada rentang tahun 2002–2004, sehingga generalisasi terhadap pola hubungan lintas generasi digital dan budaya lokal memerlukan kehati-hatian.
- **Bukan Hubungan Sebab-Akibat:** Fitur-fitur penting yang teridentifikasi merupakan korelasi statistik prediktif, bukan bukti kausal mutlak bahwa mengubah satu aspek pasti menjamin keberhasilan hubungan.
- **Langkah Lanjutan:** Melakukan penyesuaian ambang batas probabilitas (*threshold tuning*) pada model Random Forest guna meningkatkan sensitivitas deteksi (*Recall*) tanpa mengorbankan ketepatan (*Precision*) secara berlebihan.